

Diagnóstico de Marca Empleadora con Reseñas de Glassdoor

Un reto de NLP con impacto directo en retención y atracción de talento

1. Contexto de negocio

Escenario

Trabajas como data scientist en una empresa que eliges tú. El departamento de Recursos Humanos pide al equipo de Data Science un diagnóstico de la compañía como empleador a partir de las reseñas públicas de Glassdoor.

El objetivo es identificar los puntos fuertes, que se pueden explotar en employer branding y en los procesos de selección, y las áreas de mejora que están dañando la reputación o provocando la salida de empleados. Todo ello comparado con los principales competidores (peers), porque un problema solo es prioritario si estamos peor que el mercado.

Un diagnóstico mal calibrado tiene coste real: si se sobreestima un problema, RRHH invierte en la palanca equivocada; si no se detecta una debilidad, la rotación no deseada continúa. Tus conclusiones deben estar respaldadas por datos y ser comprensibles para alguien de RRHH sin perfil técnico.

2. Dataset

Glassdoor Job Reviews 1 y 2 — David Gauthier (Kaggle)

- **Fuente:** unión de los dos datasets de Glassdoor del autor (el primero centrado en Reino Unido, el segundo con cobertura global), preparada por el profesor. Se entrega en un único fichero Parquet.
- **Ventana temporal:** últimos 5 años del dataset combinado (julio 2018 – julio 2023).
- **Empresas:** solo empresas con al menos 300 reseñas. Reseñas duplicadas entre ambas fuentes eliminadas.
- **Volumen:** [n.º de reseñas] · [n.º de empresas]
- **No hay variable target:** es un ejercicio de NLP descriptivo (sentimiento y topics), no de predicción.

Variables disponibles:

Variable	Tipo	Descripción
<i>firm</i>	Categórica	Empresa, con el nombre de Glassdoor (p. ej. Deutsche-Bank)
<i>date_review</i>	Fecha	Fecha de la reseña



Variable	Tipo	Descripción
<i>current</i>	Texto	Situación y antigüedad (p. ej. "Former Employee, more than 3 years")
<i>overall_rating</i>	Numérica (1-5)	Puntuación global de la empresa
<i>recommend</i>	Categorica	¿Recomendaría la empresa? v = sí, o = sin opinión, x = no
<i>pros</i>	Texto libre	Aspectos positivos según el empleado
<i>cons</i>	Texto libre	Aspectos negativos según el empleado

Para cargar solo tu empresa y tus peers, sin leer el fichero entero:

```
pd.read_parquet('glassdoor_reviews_hr.parquet', filters=[('firm', 'in',
lista_empresas)])
```

Elección de empresa y peers

Elige una empresa y entre 3 y 5 peers del mismo sector y de tamaño comparable. Justifica la elección en una o dos frases: la comparación solo tiene sentido si los peers compiten por el mismo tipo de talento.

Si alguna empresa tiene muchas reseñas, puedes trabajar con una muestra (por ejemplo, 2.000 por empresa, con semilla fija) para que los modelos corran en tiempos razonables. Se recomienda Google Colab con GPU.

3. Proceso esperado

3.1 Preparación y EDA

- Separa *current* en situación (empleado actual / antiguo) y antigüedad.
- Por empresa: número de reseñas, rating medio, % que recomienda la empresa y reparto entre actuales y antiguos.
- Evolución del rating a lo largo de la ventana temporal.
- Al menos una conclusión accionable por sección del EDA.

3.2 Sentimiento en pros y cons (control de calidad)

- Aplica un modelo transformer preentrenado (p. ej. `distilbert-base-uncased-finetuned-sst-2-english`) sobre pros y cons por separado.
- Calcula por empresa el % de pros clasificados como positivos y el % de cons clasificados como negativos. La gran mayoría debería coincidir con lo esperado; si no, algo falla (modelo, truncado o limpieza).
- Lee una muestra de casos discordantes (cons positivos, pros negativos) y explica qué tipo de reseñas son.

**Longitud de los textos**

Los modelos tipo BERT procesan un máximo de 512 tokens. Usa `truncation=True` en el pipeline para evitar errores con las reseñas largas.

3.3 Topic modeling

- Aplica BERTopic (u otra técnica vista en clase, justificando la elección) sobre los pros y, por separado, sobre los cons.
- Decide qué hacer con las reseñas que el modelo no asigna a ningún topic (outliers) y justifícalo.
- Agrupa los topics en categorías de negocio interpretables por RRHH (p. ej. compensación, conciliación, dirección, carrera, cultura) y revisa a mano las asignaciones.

Regla de comparabilidad

Entrena un único modelo de topics con las reseñas de tu empresa y de todos sus peers juntas (uno para pros y otro para cons). Si entrenas un modelo por empresa, los topics no coincidirán y no podrás compararlos.

3.4 Comparación con peers

- Calcula el % de reseñas de cada empresa que cae en cada categoría, en pros y en cons, y compara tu empresa con la media de los peers.
- Calcula el balance neto por categoría (% en pros – % en cons) y el gap frente a la media de los peers.
- Contrasta las conclusiones del texto con `overall_rating` y `recommend`: si una categoría es de verdad un problema, las reseñas que se quejan de ella deberían tener peor rating.

Cuidado con los porcentajes

Los porcentajes de cada empresa suman 100%, así que son relativos. Si una empresa tiene pocas quejas de salario, el peso de "salario" en sus cons baja, pero sube el del resto aunque nada haya empeorado. Un % alto en cons no significa por sí solo "estamos peor": por eso se pide el balance neto.

3.5 Empleados actuales vs. antiguos

- Compara las categorías que aparecen en los cons de empleados actuales y antiguos de tu empresa.
- Los cons de los antiguos empleados son, en la práctica, motivos de salida: compáralos con los de los peers.
- Los antiguos empleados puntúan más bajo en todas las empresas (sesgo de selección). La comparación útil es la de temas, no la de sentimiento.



3.6 Áreas de mejora y recomendaciones

- Construye una matriz de priorización: peso de cada categoría en los cons de tu empresa frente a su desventaja respecto a los peers.
- Propón como máximo 3 recomendaciones concretas, redactadas para alguien de RRHH sin perfil técnico.
- Indica las limitaciones del análisis (representatividad de Glassdoor, mezcla de países y áreas, precisión de los topics).

3.7 Extra (opcional, suma nota)

- Evolución temporal de las principales categorías (p. ej. antes y después de 2020).
- Análisis por antigüedad o por recomendación.

4. Entregables

- Jupyter notebook:
 1. Un único Jupyter Notebook limpio y reproducible (ejecutable de arriba abajo sin errores)
 2. Con comentarios en el código que expliquen las decisiones tomadas
 3. Una celda de conclusiones al final con los hallazgos de negocio más relevantes
 4. Formato de entrega: notebook .ipynb
- Presentación: el ejercicio se presentará durante la clase en formato ppt o similar. Para aquellos que no puedan presentarlo ese día tendréis que entregar un vídeo con la explicación.
- **Plazo:** una semana desde la publicación del enunciado.

5. Criterios de evaluación

Entregable	Criterio principal	Peso
Notebook	EDA, control de calidad del sentimiento, topic modeling y etiquetado, comparación con peers, análisis de actuales vs. antiguos, calidad de los insights de negocio.	60%
Presentación	Problema de negocio, empresa y peers elegidos, fortalezas y áreas de mejora, propuesta de acciones para RRHH, limitaciones y próximos pasos (qué otros análisis o modelos proponemos).	40%

La nota máxima requiere que todas las decisiones técnicas (modelo de sentimiento, parámetros de BERTopic, tratamiento de outliers, agrupación en categorías) estén justificadas desde la perspectiva de negocio, no solo desde la metodológica.



6. Referencias y recursos

- Gauthier, D. Glassdoor Job Reviews [dataset].
kaggle.com/datasets/davidgauthier/glassdoor-job-reviews
- Gauthier, D. Glassdoor Job Reviews 2 [dataset].
kaggle.com/datasets/davidgauthier/glassdoor-job-reviews-2
- https://scholar.google.com/citations?view_op=view_citation&hl=en&user=FQstpaoAAAAJ&citation_for_view=FQstpaoAAAAJ:UebtZRa9Y70C
- Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. arXiv:2203.05794.
- Sanh, V., Debut, L., Chaumond, J. & Wolf, T. (2019). DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. arXiv:1910.01108.